

数据压缩入门

**文件变小，
信息去哪了？**

Data compression 101

这节课要弄清四件事

数据压缩

为何压缩


怎样变小

能否恢复

怎样选择

学到哪里，
就补到哪里。

文件变小，是不是删掉了内容？




A : 4096 B

B : 38 B


B 由 A 编码得到。先预测，再检查。

文件变小，是不是删掉了内容？



A : 4096 B

B : 38 B



从 B 读回的图

B 由 A 编码得到。先预测，再检查。

连续重复的颜色，怎样少写一些？



用短消息传给同桌：顺序不变，内容不漏。

连续重复的颜色，怎样少写一些？



用短消息传给同桌：顺序不变，内容不漏。

红 8 绿 5 蓝 3

游程编码 Run-Length Encoding (RLE)

少写以后，怎样证明一个也没丢？

原串	红	红	红	红	红	红	红	绿	绿	绿	绿	绿	蓝	蓝	蓝
待查	红	红	红	红	红	红	红	蓝	绿	绿	绿	绿	蓝	蓝	蓝

提出检验方法，再检查这份还原结果。

少写以后，怎样证明一个也没丢？

原串	红	红	红	红	红	红	红	绿	绿	绿	绿	绿	蓝	蓝	蓝
待查	红	红	红	红	红	红	红	蓝	绿	绿	绿	绿	蓝	蓝	蓝

提出检验方法，再检查这份还原结果。

少写以后，怎样证明一个也没丢？

原串	红	红	红	红	红	红	红	绿	绿	绿	绿	绿	蓝	蓝	蓝
待查	红	红	红	红	红	红	红	绿	绿	绿	绿	绿	蓝	蓝	蓝

16 项逐值一致。

开场：4096 bytes 还原一致（ True ）。

无损：解压后可完全恢复原始数据。

同一规则，为什么有时反而变大？



每组：颜色编号 1 B + 连续次数 1 B

同一规则，为什么有时反而变大？



每组：颜色编号 1 B + 连续次数 1 B

A : 16 B → 6 B B : 16 B → 32 B

重复可以少写；无损必须完整恢复

数据压缩

为何压缩

特殊编码，减少存储 / 传输数据量
效果取决于数据、方法与开销

怎样变小

去除冗余：连续重复写成次数


能否恢复

无损：可完全恢复原始数据

怎样选择


无损不保证
每份数据
都变小。

相邻值接近，怎样完整记录？



灰度 0-255，每项 8 bit；必须完整恢复。


相邻值接近，怎样完整记录？



灰度 0-255，每项 8 bit；必须完整恢复。

起点 120；差值：+1，+1，-1，-1，0，+1，+1

相邻值接近，怎样完整记录？



灰度 0-255，每项 8 bit；必须完整恢复。

本串码表：-1 = 00；0 = 01；+1 = 10

起点 120；差值：+1，+1，-1，-1，0，+1，+1

$8 + 7 \times 2 = 22 \text{ bit} \rightarrow 3 \text{ B}$ （补 2 bit）

只留近似值，还能找回原数吗？

归到最近的 4 的倍数；中点向上取。

116

120

124

看到代表值 120，原来可能是多少？

只留近似值，还能找回原数吗？

归到最近的 4 的倍数；中点向上取。

116

120

124

看到代表值 120，原来可能是多少？

120 → 120 121 → 120

只留近似值，还能找回原数吗？

归到最近的 4 的倍数；中点向上取。

116

120

124

看到代表值 120，原来可能是多少？

120 → 120 121 → 120

$8 \times 6 = 48 \text{ bit} = 6 \text{ B}$ ；不能保证完整恢复

看起来差不多，能否叫无损？

A



B



两图均为 1020×1500 像素；以所提供 JPEG 本次解码的 RGB 为起点。

看起来差不多，能否叫无损？

A



B



比较本次输入 RGB ； 不证明更早的原图无损。

PNG ： 本次回读像素一致

JPEG ： 504,742 个像素改变

看起来差不多，能否叫无损？

A



同一 192×128 像素区域，最近邻放大 4 倍

PNG：本次回读像素一致

B




JPEG：504,742 个像素改变

看起来差不多，能否叫无损？

这份绘画图像（1020 × 1500）

PNG 1,706,860 B JPEG 240,848 B



CODE 8B3
012345

程序绘制的测试图（384 × 216）

PNG 4,441 B

JPEG 10,766 B

有损 / 无损说明能否精确恢复，不能替我们排文件大小。

利用关系能无损；舍弃区分会有损

数据压缩

看起来相似，
不能证明
原值相同。

为何压缩

特殊编码，减少存储 / 传输数据量
效果取决于数据、方法与开销

怎样变小

去除冗余：连续重复写成次数
利用相关：首值 + 完整差值
感知近似：舍弃不敏感的区别

能否恢复

无损：可完全恢复原始数据
有损：不能保证完全恢复

怎样选择

同一种误差，哪些任务能接受？

任务	变化
通知原文	本周五交作业 → 本周交作业
源程序	<code>score >= 60</code> → <code>score > 60</code> ； 输入 60
照片浏览副本	像素略变，人物与活动内容仍清楚

同一种误差，哪些任务能接受？

任务	变化
通知原文	本周五交作业 → 本周交作业
源程序	score >= 60 → score > 60 ; 输入 60
照片浏览副本	像素略变，人物与活动内容仍清楚

文本文档 / 程序必须无损；媒体要检查用途与质量。

看扩展名，就能判定压缩方式吗？

“JPG、TIF、MP3、MPEG 都是有损；图片不能无损。”

TIFF 配置卡	可选方式
编码设置	未压缩 / LZW 无损 / JPEG 有损

已有证据：本课 PNG 回读像素一致。

看扩展名，就能判定压缩方式吗？

“JPG、TIF、MP3、MPEG 都是有损；图片不能无损。”

TIFF 配置卡	可选方式
编码设置	未压缩 / LZW 无损 / JPEG 有损

已有证据：本课 PNG 回读像素一致。

TIF 需看编码；图片也能无损压缩。

看扩展名，就能判定压缩方式吗？

名称	常见用途	本课保留的边界
JPG/JPEG	图像	常见照片保存通常有损
TIF/TIFF	图像	需看所用编码方式
MP3	音频	常见有损音频编码
MPEG	视频相关标准	常见视频用途采用有损编码

先看用途与保存方式，再判断。

能否接受有损，要看用途与编码

数据压缩

为何压缩

特殊编码，减少存储 / 传输数据量
效果取决于数据、方法与开销

怎样变小

去除冗余：连续重复写成次数
利用相关：首值 + 完整差值
感知近似：舍弃不敏感的区别

能否恢复

无损：可完全恢复原始数据
有损：不能保证完全恢复

怎样选择

文本文档 / 程序：必须无损
媒体：所需主要信息仍可获取
格式名不足；TIF 须查具体编码

媒体接受有损，
需要质量达标。

大小和信息要求，怎样同时满足？

限额 100 KiB ； 1 KiB = 1024 B 。以下为题目给定结果。

任务（原 120 KiB ）	方案 A	方案 B
源程序 bytes 须完整恢复	无损 80 KiB 解压 bytes 一致	删改内容 50 KiB 不能恢复原 bytes
照片浏览，人物主题清楚	无损 110 KiB 回读像素一致	有损 70 KiB 人物主题仍清楚

逐份选方案，并说明另一种为什么不合格。

大小和信息要求，怎样同时满足？

限额 100 KiB ； 1 KiB = 1024 B 。以下为题目给定结果。

任务（原 120 KiB ）	方案 A	方案 B
源程序 bytes 须完整恢复	无损 80 KiB 解压 bytes 一致	删改内容 50 KiB 不能恢复原 bytes
照片浏览，人物主题清楚	无损 110 KiB 回读像素一致	有损 70 KiB 人物主题仍清楚

逐份选方案，并说明另一种为什么不合格。

源程序选 A ； 照片浏览副本选 B 。两项要求都要满足。

用完整知识树检查压缩方案

数据压缩

大小和信息
两项要求
都要满足。

为何压缩

特殊编码，减少存储 / 传输数据量
效果取决于数据、方法与开销

怎样变小

去除冗余：连续重复写成次数
利用相关：首值 + 完整差值
感知近似：舍弃不敏感的区别

能否恢复

无损：可完全恢复原始数据
有损：不能保证完全恢复

怎样选择

文本文档 / 程序：必须无损
媒体：所需主要信息仍可获取
格式名不足；TIF 须查具体编码
大小、信息要求都要满足

用两句话检查自己的判断

独立写 40 秒：

无损判断要比较 _____ 与 _____ 。

照片看不出变化仍可能有损，因为 _____ 。

用两句话检查自己的判断

独立写 40 秒：

无损判断要比较 _____ 与 _____ 。

解压结果 与 原始输入

照片看不出变化仍可能有损，因为 _____ 。

感知相似，不能证明每个原值都相同。